Raport - Lista 1

Paweł Karwecki

2.04.2025

Spis treści

1	Krótki opis zagadnienia	1
	1.1 Informacja o danych	1
	1.2 Opis poszczególnych cech	
	1.3 Podstawowe informacje o danych	
2	Opis eksperymentów/analiz	9
3	Wyniki	:
	3.1 Analiza ogólna	3
	3.2 Analiza z podziałem na aktualnych i byłych klientów	15
4	Podsumowanie	27
	4.1 Ogólne wnioski o klientach	27
	4.2 Wnioski o klientach odchodzacych	

1 Krótki opis zagadnienia

1.1 Informacja o danych

Plik źródłowy zawiera dane na temat klientów pewnej firmy telekomunikacyjnej. Każdy z 7043 wierszy reprezentuje jednego, unikatowego klienta. Jest 21 kolumn, które zawierają chociażby informacje na temat wykopionych usług, danych demograficznych klientów i, przede wszystkim, czy nadal są aktywnymi klientami firmy. Dane pochodzą ze strony: https://www.kaggle.com/datasets/blastchar/telco-customer-churn

1.2 Opis poszczególnych cech

Tabela 1: Rodzaj zmiennych i wytłumaczone nazwy cech

Nazwa	Тур	
zmiennej	zmiennej	Opis zmiennej
customerID	factor	Identyfikator klienta
gender	factor	Płeć
SeniorCitizen	integer	Czy klient jest na emeryturze
Partner	factor	Czy klient ma partnera/partnerkę
Dependents	factor	Czy klient ma na utrzymaniu inne osoby
tenure	integer	Ile miesięcy klient jest związany z firmą
PhoneService	factor	Czy klient ma wykupioną usługę telefoniczą
MultipleLines	factor	Czy klient ma wykupioną usługę możliwości wielu połączeń telefonicznych
		jednocześnie
InternetService	factor	Czy klient ma wykupioną usługę internetową

Nazwa	Тур	
zmiennej	zmiennej	Opis zmiennej
OnlineSecurity	factor	Czy klient ma wykupioną usługę bezpieczeństwa w sieci
OnlineBackup	factor	Czy klient ma wykupioną usługę kopii zapasowej danych w sieci
DeviceProtection	factor	Czy klient ma wykupioną usługę ochrony urządzenia elektronicznego
TechSupport	factor	Czy klient ma wykupioną usługę wsparcia technicznego
StreamingTV	factor	Czy klient ma wykupioną usługę dostępu do telewizji internetowej
StreamingMovies	factor	Czy klient ma wykupioną usługę dostępu do portali streamingowych
Contract	factor	Jak długo trwa umowa
PaperlessBilling	factor	Czy klient otrzymuje elektroniczne rozliczenie
PaymentMethod	factor	Metoda płatności klienta
MonthlyCharges	numeric	Opłata miesięczna
TotalCharges	numeric	Suma opłat
Churn	factor	Czy klient odszedł w przeciągu ostatniego miesiąca

1.3 Podstawowe informacje o danych

Na początku sprawdźmy, czy mamy jakieś brakujące wartości.

Tabela 2: Analiza brakujących wartości

	tenure	Churn	TotalCharges
489	0	No	NA
754	0	No	NA
937	0	No	NA
1083	0	No	NA
1341	0	No	NA
3332	0	No	NA
3827	0	No	NA
4381	0	No	NA
5219	0	No	NA
6671	0	No	NA
6755	0	No	NA

W tabeli 2 widać, że brakujące wartości są jedynie w kolumnie TotalCharges. Każdy z tych klientów ma również w kolumnie tenure wartość 0, co może wskazywać na to, że są to osoby, które są klientami firmy przez mniej niż miesiąc. Następnym krokiem będzie sprawdzenie jakie wartości występują w danych kolumnach.

Tabela 3: Wartości cech

Nazwa zmiennej	Wartości zmiennej
gender	Female, Male
SeniorCitizen	TRUE
Partner	Yes, No
Dependents	No, Yes
tenure	TRUE
PhoneService	No, Yes
MultipleLines	No phone service, No, Yes
InternetService	DSL, Fiber optic, No
OnlineSecurity	No, Yes, No internet service
OnlineBackup	Yes, No, No internet service

Nazwa zmiennej	Wartości zmiennej
DeviceProtection	No, Yes, No internet service
TechSupport	No, Yes, No internet service
StreamingTV	No, Yes, No internet service
StreamingMovies	No, Yes, No internet service
Contract	Month-to-month, One year, Two year
PaperlessBilling	Yes, No
PaymentMethod	Electronic check, Mailed check, Bank transfer (automatic), Credit card (automatic)
MonthlyCharges	TRUE
TotalCharges	NA
Churn	No, Yes

Tabela 3 powstała w następujący sposób: w wierszach cech typu factor wypisujemy wszystkie podane wartości. Jeśli dana zmienna jest typu numeric oraz wszystkie jej wartości sa większe lub równe 0, to zwracamy TRUE. Jak widać, jedynie w kolumnie TotalCharges mamy coś innego niż TRUE, co zgadza się ze wcześniejszym sprawdzeniem. Możemy zatem przyjać, że jedynym sposobem na uzupełnianie wartości brakujących jest wartość NA.

2 Opis eksperymentów/analiz

Analiza będzie miała charakter opisowy. Na podstawie różnych wykresów (np. wykres słupkowy, wykres rozrzutu) oraz wskaźników sumarycznych postaramy się przeanalizować sytuację firmy. Wykorzystane zostaną:

- Miary położenia:

 - Średnia próbkowa: $\overline{X} = \frac{1}{n} \sum_{i=1}^{n} X_i$ Kwantyle rzędu p: $F^{-1}(p) = \inf\{t : F(t) \ge p\}$ Mediana: kwantyl rzędu $\frac{1}{2}$
- Miary rozproszenia/rozrzutu:

 - Odchylenie standardowe: $S = \sqrt{\frac{1}{n-1} \sum_{i=1}^{n} (X_i \overline{X})^2}$ Współczynnik korelacji Pearsona: $r_{xy} = \frac{\sum_{i=1}^{n} (X_i \overline{X})(Y_i \overline{Y})}{\sqrt{\sum_{i=1}^{n} (X_i \overline{X})^2} \sqrt{\sum_{i=1}^{n} (Y_i \overline{Y})^2}}$
- Miary asymetrii:
 - Współczynnik skośności: $skewness = \frac{\sqrt{n}\sum_{i=1}^{n}(X_i-\overline{X})^3}{(\sum_{i=1}^{n}(X_i-\overline{X})^2)^{\frac{3}{2}}}$

gdzie n - długość wektora danych, X,Y - wartości danych, F - dystrybuanta

3 Wyniki

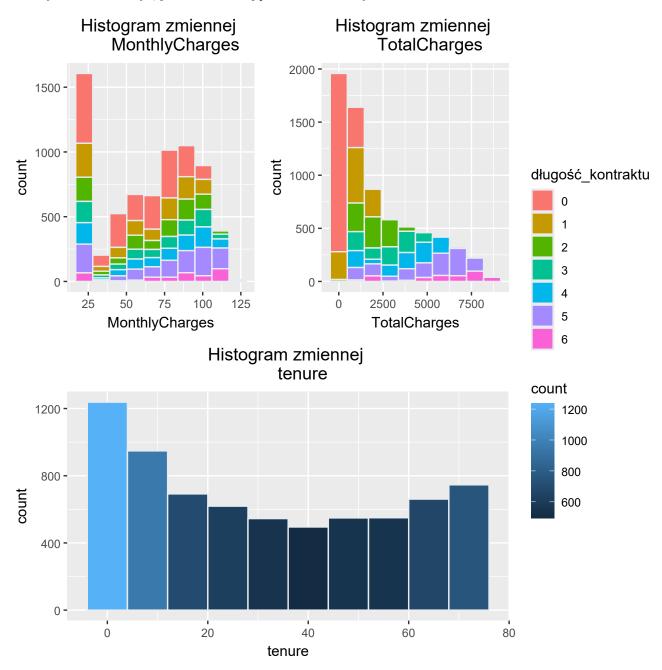
Analiza ogólna 3.1

Spójrzmy najpierw na podstawowe miary wybranych zmiennych:

Tabela 4: Podstawowe miary zmiennych ilościowych

Statystyka	Min.	1st Qu.	Median	Mean	3rd Qu.	Max.	$Odchylenie_Standardowe$	Skośność
TotalCharges	18.8	401.4	1397.5	2283.3	3794.7	8684.8	2266.8	1.0
tenure	0.0	9.0	29.0	32.4	55.0	72.0	24.6	0.2
MonthlyCharges	18.2	35.5	70.3	64.8	89.8	118.8	30.1	-0.2

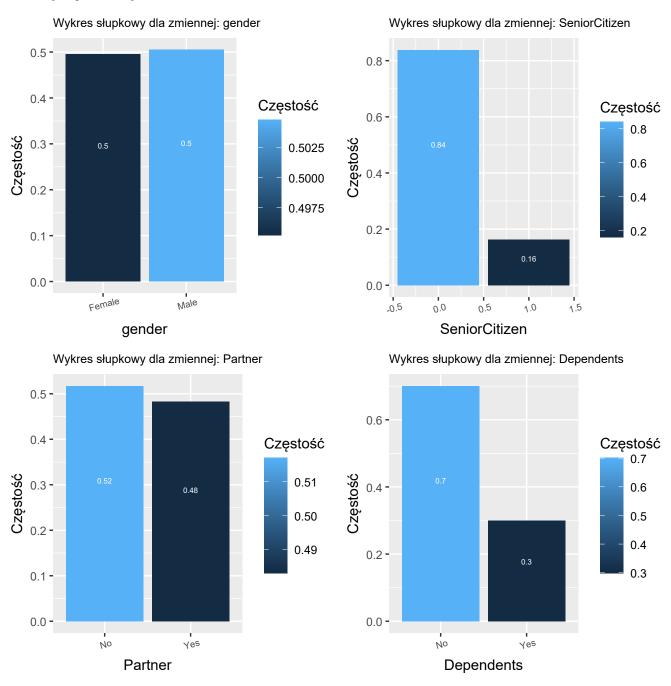
Tabela 4 przedstawia podstawowe miary dla cech numerycznych o większym zbiorze wartości niż 0 i 1. Jak widać, mamy bardzo duże odchylenie standardowe w kolumnie TotalCharges, bliskie średniej. Pokazuje to duże oddalenie od średniej w łącznych płacach klientów. Miary cechy tenure wskazują na to, że prawie połowa klientów firmy była związana z nią przez ponad 2.5 roku, ale aż 25% umów z konsumentami nie przekracza roku, co może tłumaczyć wysokie odchylenie standardowe w TotalCharges. Obie te zmienne mają rozkład prawostronnie skośny. W MothlyCharges widać również, że większość klientów miesięcznie płaci więcej, niż wynosi średnia. Ta zmienna, w przeciwieństwie do poprzednich, ma jednak rozkład lewostronnie skośny. Warto zobaczyć, jaki rozkład mają te zmienne na wykresie.



Rysunek 1: Histogramy wybranych zmiennych ilościowych

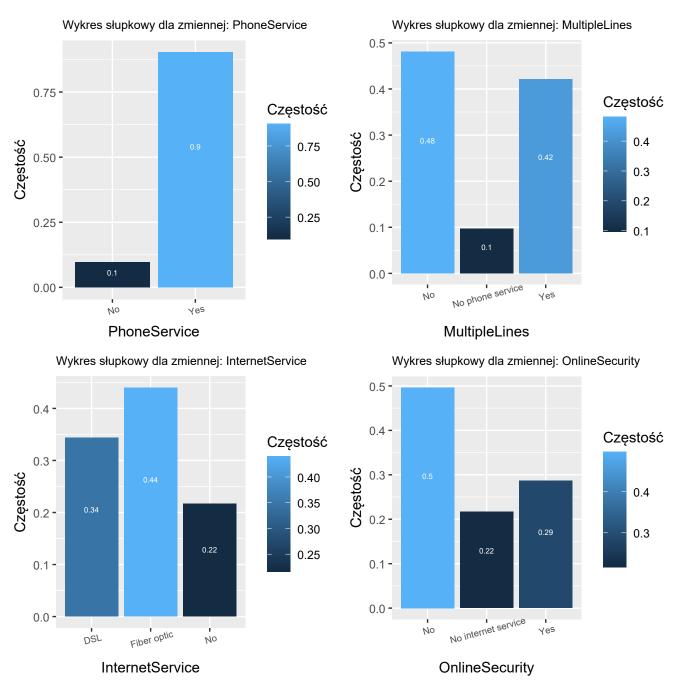
Na rysunku 1 z wykresu w lewym górnym rogu jesteśmy w stanie odczytać, iż w większości podziałów na kwoty, najliczniejszą część stanowią klienci stosunkowo nowi - związani z firmą przez okres krótszy niż rok. Dopiero przy miesięcznej opłacie w okolicach 100 dolarów widać, że najliczniejszą grupę tworzą konsumenci

o długości kontraktu dłuższej niż 5 lat. Na histogramie po prawej widać gwałtowny spadek od początku wykresu, aż do punktu 2500 dolarów. Po tej kwocie również są spadki, ale tym razem są już stopniowe, nie ma aż tak wielkich przeskoków między słupkami. Dolny wykres z kolei pokazuje, że spora część naszych klientów jest związana z firmą przez okres krótszy niż 2 lata. Przypatrzmy się teraz wykresom poszczególnych zmiennych jakościowych.

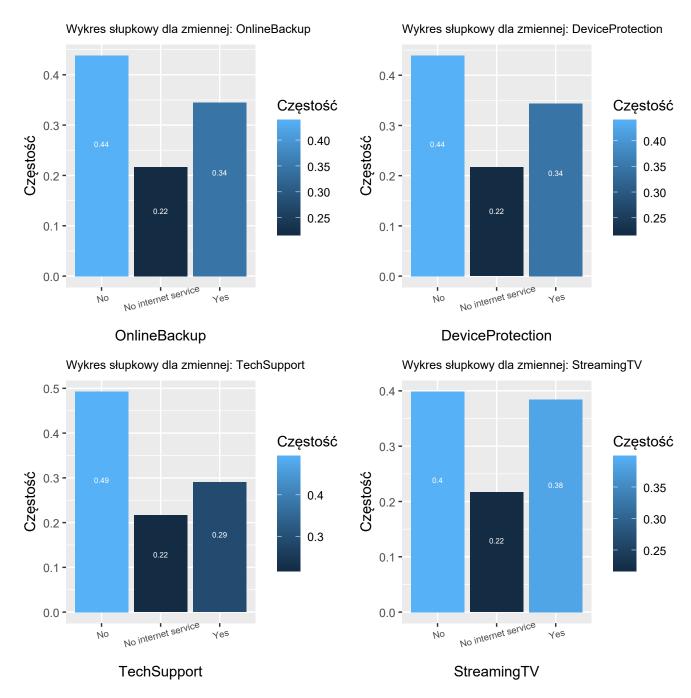


Rysunek 2: Wykresy słupkowe wybranych zmiennych jakościowych

Z wykresów 2 widać, że duży odsetek naszy klientów stanowią osoby przed emeryturą oraz osoby z niezależnością finansową. Mamy również podobny rozkład w cechach gender oraz partner.

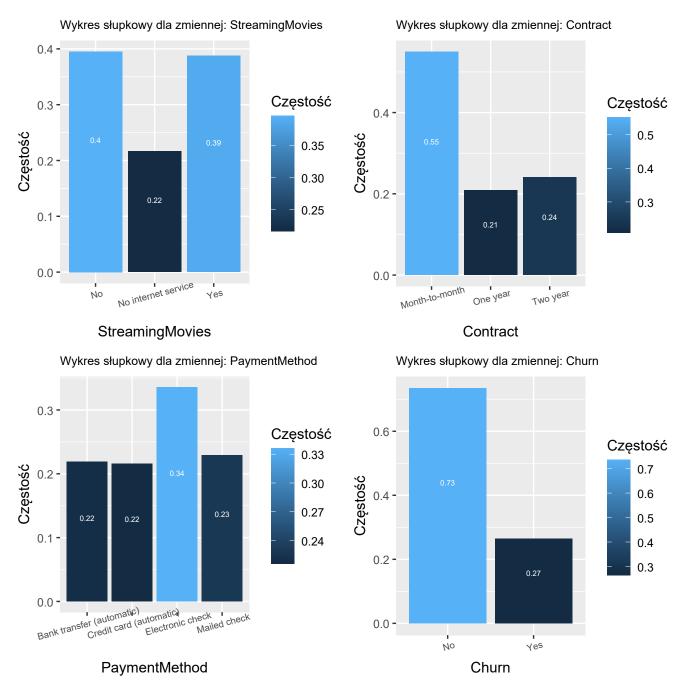


Rysunek 3: Wykresy słupkowe wybranych zmiennych jakościowych



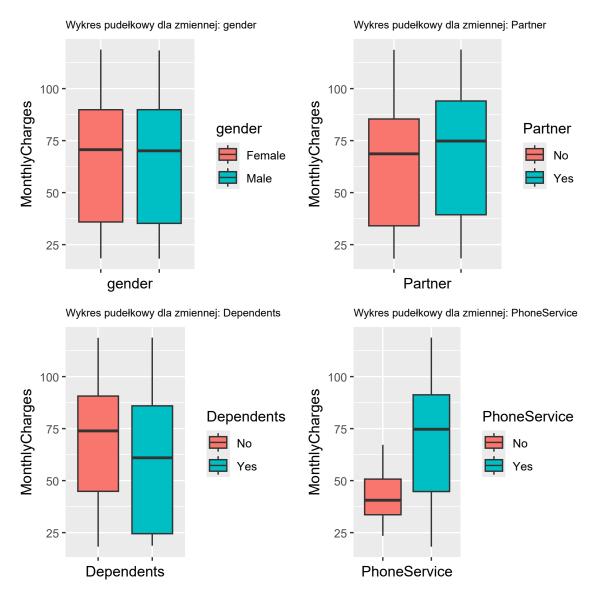
Rysunek 4: Wykresy słupkowe wybranych zmiennych jakościowych

Rysunek 3 pokazuje, że największym zainteresowaniem cieszy się oferta usługi telefonicznej, ale jej rozszerzenie wybrało mniej niż połowa konsumentów. Usługi sieciowe wykupiło 78% użytkowników, jednakże wszelkie dodatki (poza StreamingTV oraz StreamingMovies) zwróciło uwagę mniej niż 35% nabywców (widoczne na wykresach słupkowych 3, 4, 5), co może być spowodowane ich niską jakością, ceną lub braku ludzkiej potrzeby.



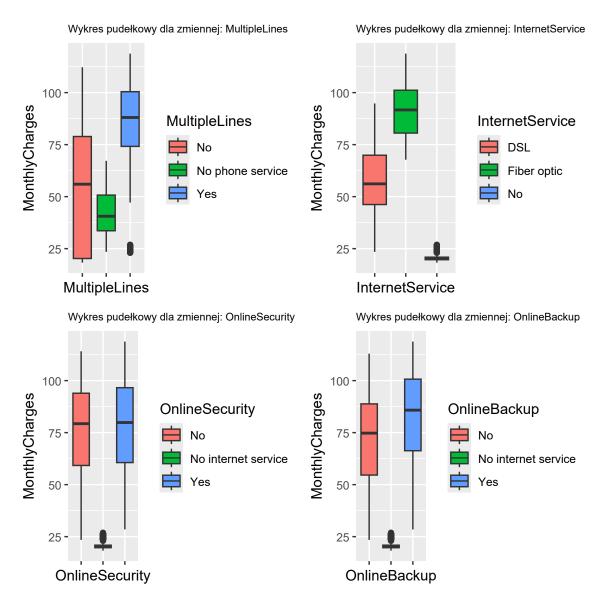
Rysunek 5: Wykresy słupkowe wybranych zmiennych jakościowych

Warte uwagi są również wybory długości umów widoczne na rysunku 5, gdyż jedynie 45% klientów zdecydowało się na umowy roczne i dłuższe. Najpopularniejszą metodą płatności jest czek elektroniczny. Niepokojące może być również to, że w ostatnim miesiącu aż 27% klientów odeszło od firmy. Sprawdźmy teraz wykresy pudełkowe poszczególnych zmiennych w zależności od miesięcznych opłat.



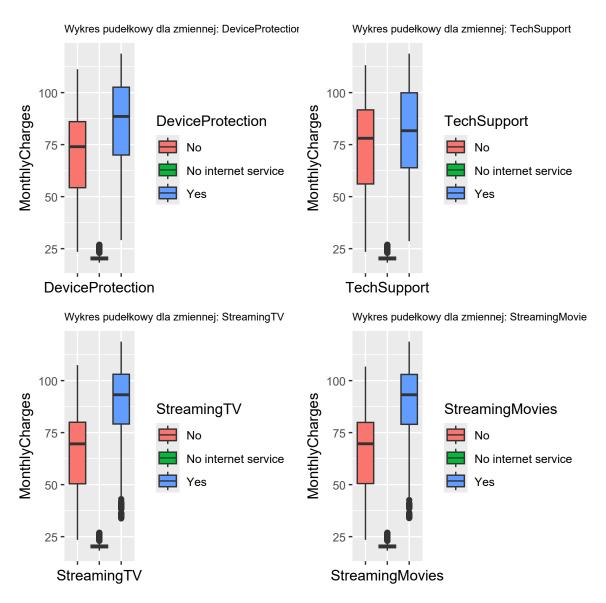
Rysunek 6: Wykresy pudełkowe wybranych zmiennych jakościowych w zależności od miesięcznej opłaty

Na rysunku 6 zauważalny jest brak różnicy w opłatach w zależności od płci. Klienci, którzy są w związku, na ogół płacą więcej. To samo można powiedzieć o nabywcach, którzy nie muszą nikogo utrzymywać (zmienna Dependents). Co ciekawe, mediana wydatków osób z wykupioną usługą PhoneService jest o wiele większa, niż osób bez niej.

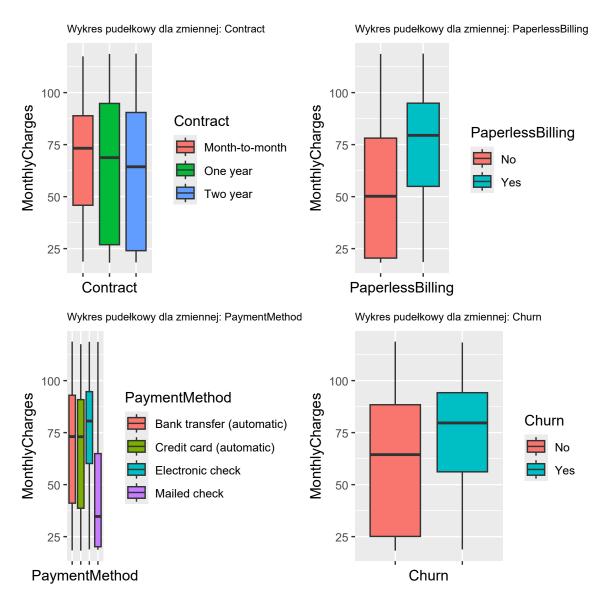


Rysunek 7: Wykresy pudełkowe wybranych zmiennych jakościowych w zależności od miesięcznej opłaty

Z rysunku 7 możemy odczytać, że klienci, którzy nabyli opcję MultipleLines na ogół płacą miesięcznie więcej od pozostałych. Podobnie jest w przypadku nabywców światłowodu (opcja Fibre optic w zmiennej InternetService). Co ciekawe, w OnlineSecurity nie widać dużego zróżnicowania w opłatach (wśród klientów z wykupionym internetem). W kolejnych dodatkach do usługi internetowej już widać rozbieżności, szczególnie w StreamingTV i StreamingMovies na wykresach 8



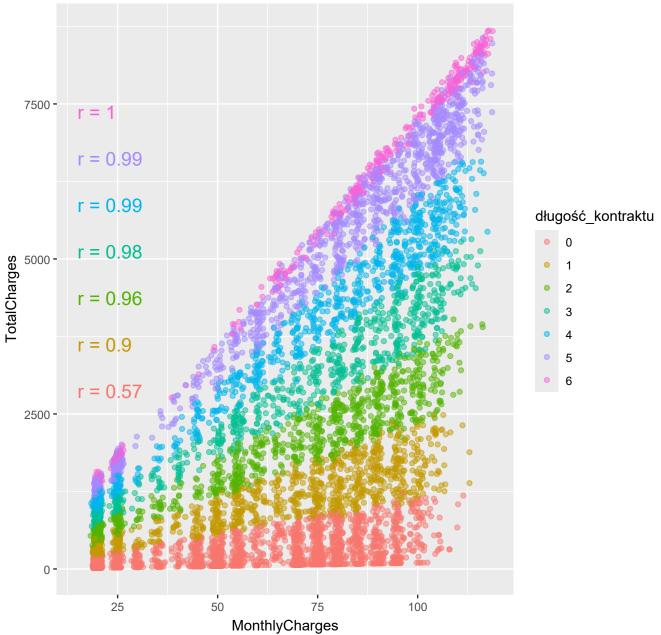
Rysunek 8: Wykresy pudełkowe wybranych zmiennych jakościowych w zależności od miesięcznej opłaty



Rysunek 9: Wykresy pudełkowe wybranych zmiennych jakościowych w zależności od miesięcznej opłaty

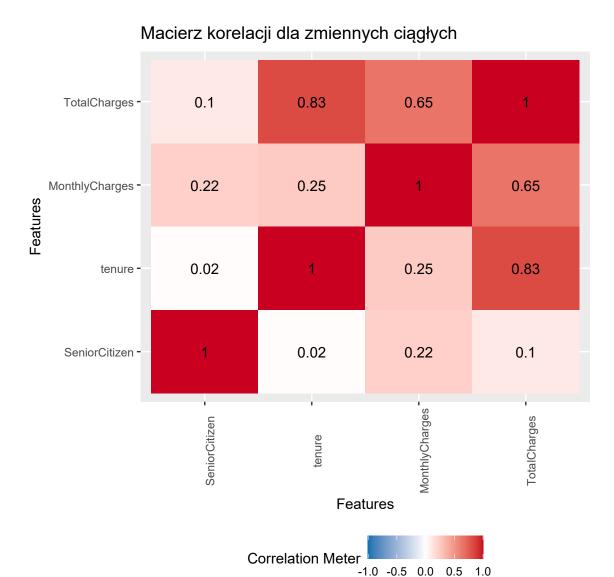
Wykresy pudełkowe na obrazku 9 również pokazują ciekawe zależności. Klienci na kontrakcie miesięcznym wykazują mniejsze zróżnicowanie i większą medianę w miesięcznych wydatkach, niż pozostali. Konsumenci, którzy nie otrzymują rozliczenia elektronicznie, na ogół płacą mniej, podobnie jak osoby płacące czekiem. Ostatni wykres wskazuje na to, że klienci, którzy odeszli w ostatnim miesiącu płacili więcej oraz ich zróżnicowanie w opłatach było mniejsze niż tych, którzy pozostali. Zbadajmy jeszcze wykres rozrzutu dla zmiennych MonthlyCharges i TotalCharges





Rysunek 10: Wykres rozrzutu dla zmiennych MonthlyCharges i TotalCharges

Wykres rozrzutu 10 pokazuje, jaki jest związek między opłatami miesięcznymi, a zsumowanymi wydatkami klientów, w zależności od ich długości kontraktu z firmą. Dla klientów, którzy z firmą są od ponad roku, korelacja między zmiennymi MonthlyCharges a TotalCharges jest bardzo silna. Z kolei w przypadku konsumentów o długości kontraktu nieprzekraczającym roku, korelacja jest średnia, co raczej nie powinno być zaskakujące, ze względu na krótki okres współpracy z firmą i duże zróżnicowanie w opłatach miesięcznych. Spójrzmy jeszcze, jak prezentuje się macierz korelacji.



Rysunek 11: Macierz korelacji dla zmiennych ciągłych (bez brakujących wartości)

Macierz 11 potwierdza silną korelację między TotalCharges a tenure. Na dosyć wysokim poziomie jest również korelacja MonthlyCharges z TotalCharges. Warto zauważyć, że zmienna SeniorCitizen raczej w żaden sposób nie wpływa na jakąkolwiek z pozostałych cech.

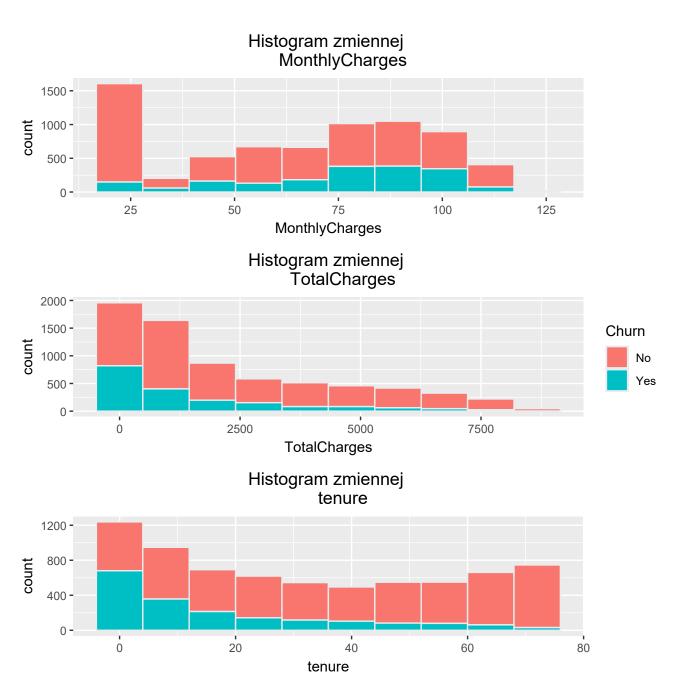
3.2 Analiza z podziałem na aktualnych i byłych klientów

Sprawdźmy teraz, co wyróżnia klientów, którzy zdecydowali się na zakończenie współpracy z firmą.

Tabela 5: Podstawowe miary zmiennych ilościowych z uwzględnieniem wartości zmiennej Churn

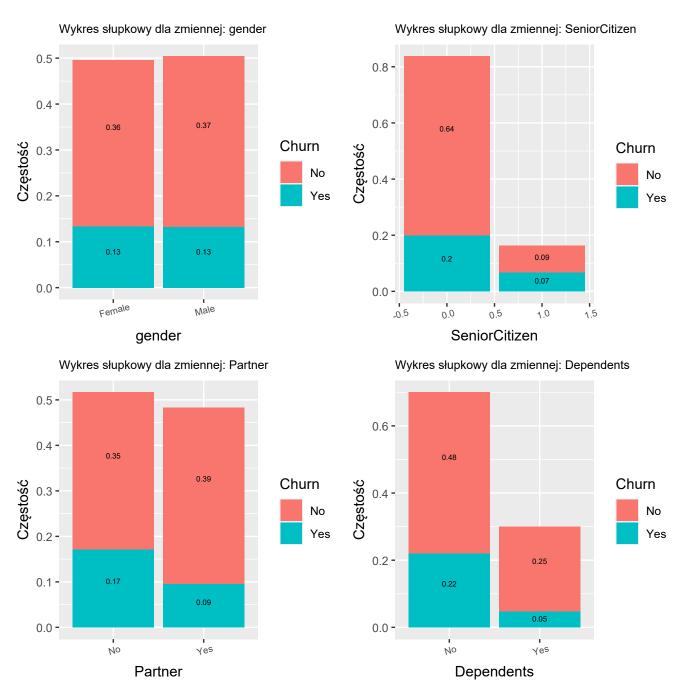
Statystyka	Churn	Min.	1st Qu.	Median	Mean	3rd Qu.	Max.	Odchylenie_Standardowe	Skośność
TotalCharges	No	18.8	577.8	1683.6	2555.3	4264.1	8672.5	2329.5	0.8
TotalCharges	Yes	18.9	134.5	703.5	1531.8	2331.3	8684.8	1890.8	1.5
tenure	No	0.0	15.0	38.0	37.6	61.0	72.0	24.1	0.0
tenure	Yes	1.0	2.0	10.0	18.0	29.0	72.0	19.5	1.1
MonthlyCharges	No	18.2	25.1	64.4	61.3	88.4	118.8	31.1	0.0
MonthlyCharges	Yes	18.9	56.1	79.7	74.4	94.2	118.3	24.7	-0.7

Z tabeli 5 wynika, że ponad 50% klientów, którzy odeszli, nie było związanych z firmą przez dłużej niż rok. To powoduje również mniejsze wartości w prawie wszystkich statystykach (poza Max.) dla cechy TotalCharges. Co również jest ciekawe, to fakt, że to samo można powiedzieć o kolumnie MonthlyCharges, tylko na odwrót - nieaktywni klienci mają większe wartości, niż ci, którzy pozostali. Możemy również odczytać, że zmienne MonthlyCharges i tenure mają rozkład symetryczny wśród aktualnych klientów, TotalCharges w obu przypadkach oraz tenure wśród byłych konsumentów mają rozkład prawostronnie skośny, a MonthlyCharges dla byłych klientów - rozkład lewostronnie skośny.



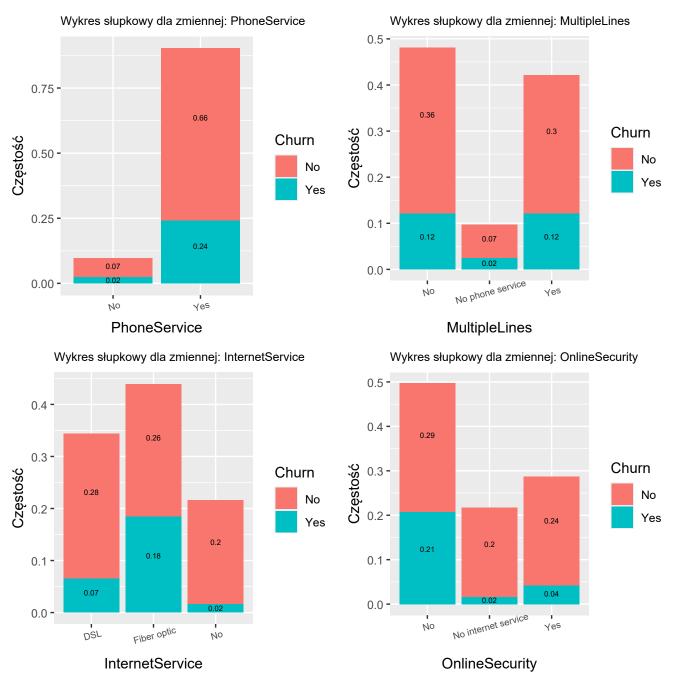
Rysunek 12: Histogramy wybranych zmiennych ilościowych z podziałem względem zmiennej Churn

Histogramy z rysunku 12 potwierdzają, że znaczna część byłych klientów wydawała miesięcznie ponad 70\$ (górny wykres). Środkowy i dolny wykres również podkreślają krótką współpracę byłych konsumentów z firmą. Następnym krokiem będzie analiza wykresów słupkowych wybranych zmiennych z podziałem ze względu na zmienną Churn.



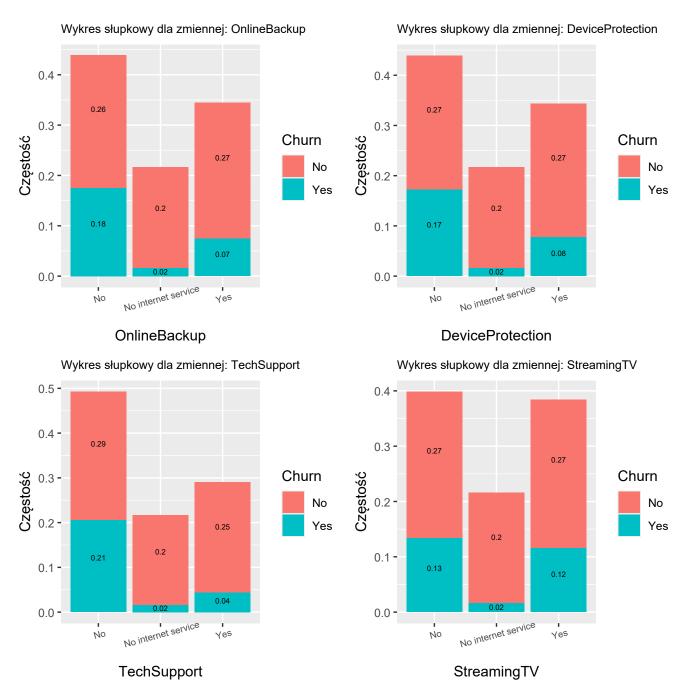
Rysunek 13: Wykresy słupkowe wybranych zmiennych jakościowych z uwzględnieniem zmiennej Churn

Z wykresów słupkowych 13 można odczytać, że niekatywni już klienci w większości nie są emerytami, nie mają partnera/partnerki oraz nie muszą nikogo utrzymywać.

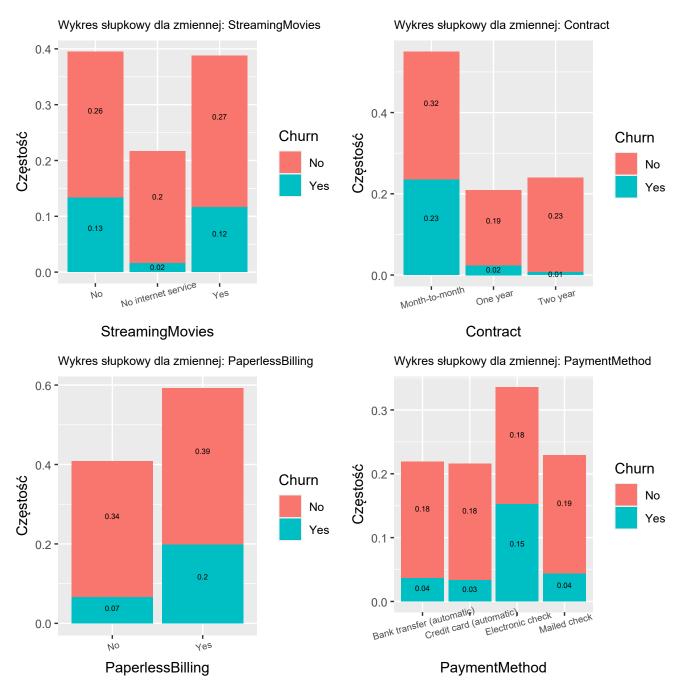


Rysunek 14: Wykresy słupkowe wybranych zmiennych jakościowych z uwzględnieniem zmiennej Churn

Aż 24% byłych konsumentów miało wykupioną usługę telefoniczną, ale tylko 12% wybrało jej rozszerzenie, czyli tyle samo, ile wybrało brak rozszerzenia. Kolejną rzeczą, którą można odczytać z rysunku 14 jest to, że aż 18% byłych konsumentów wybrało najdroższą usługę internetową - światłowód. Wybór takich dodatków jak OnlineSecurity czy OnlineBackup, DeviceProtection i TechSupport z wykresów 15 raczej nie miało dużego wpływu na rezygnację.

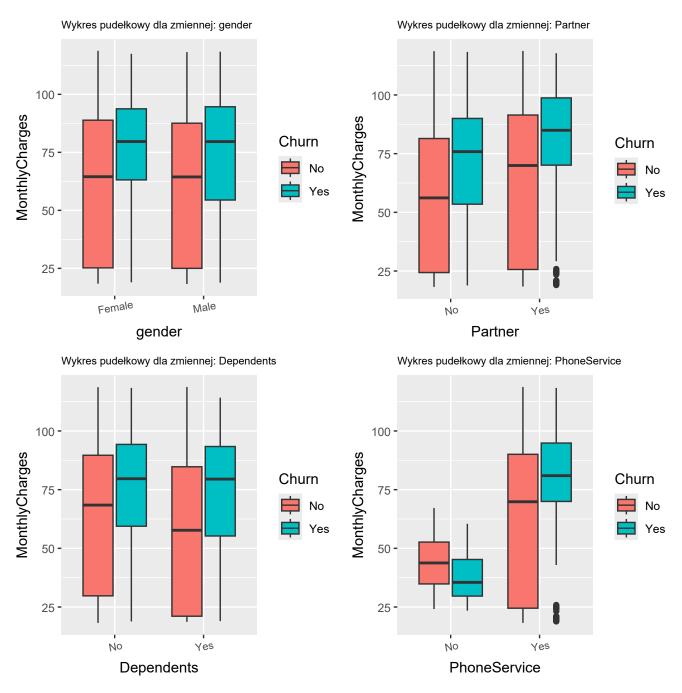


Rysunek 15: Wykresy słupkowe wybranych zmiennych jakościowych z uwzględnieniem zmiennej Churn



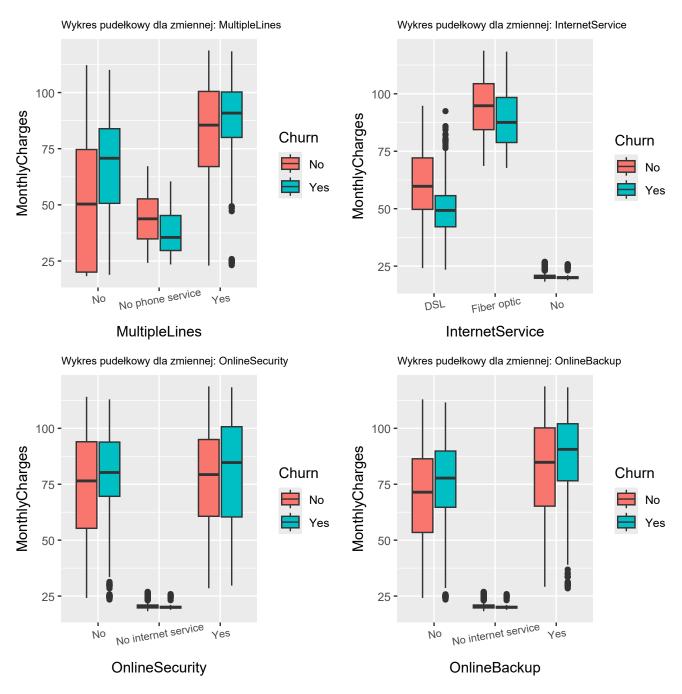
Rysunek 16: Wykresy słupkowe wybranych zmiennych jakościowych z uwzględnieniem zmiennej Churn

Widać, że dość spora część byłych klientów wybrała opcję StreamingTV oraz StreamingMovies z rysunku 16 - po 12% w każdej. Z dalszej części tego rysunku można odczytać, że bardzo duży odsetek z byłch klientów stanowią osoby z kontraktem miesięcznym. Niemały odsetek z nich wybrał również opcję elektrycznego rozliczenia i opłaty. Sprawdźmy teraz, jak wyglądają wykresy pudełkowe z podziałem na aktywność klienta.



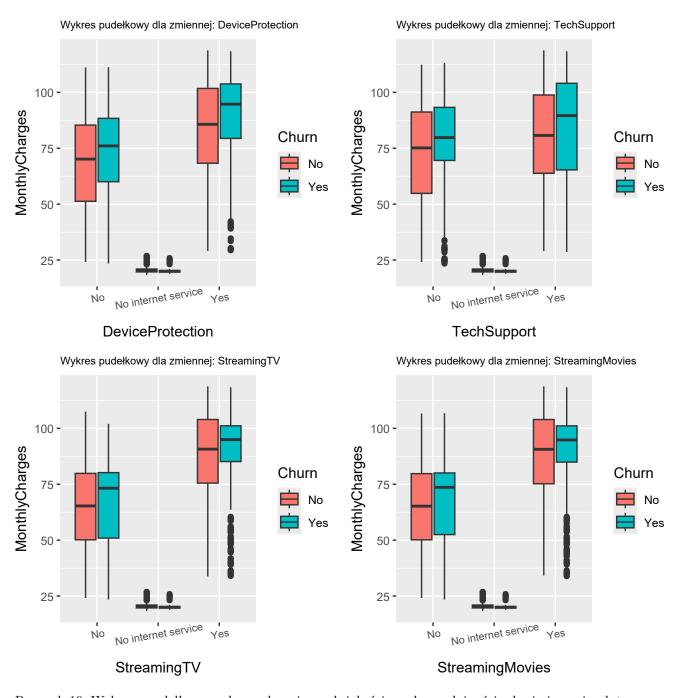
Rysunek 17: Wykresy pudełkowe wybranych zmiennych jakościowych w zależności od miesięcznej opłaty z uwzględnieniem zmiennej Churn

Na podstawie wykresów pudełkowych 17 można dojść do wniosku, że faktycznie byli klienci wydawali więcej, aczkolwiek zastanawiająca jest dysproporcja w cesze PhoneService. Osoby, które ją wykupiły, płaciły więcej od aktywnych klientów, ale ci, którzy jej nie wybrali, płacili mniej od bieżących konsumentów z tą samą opcją.



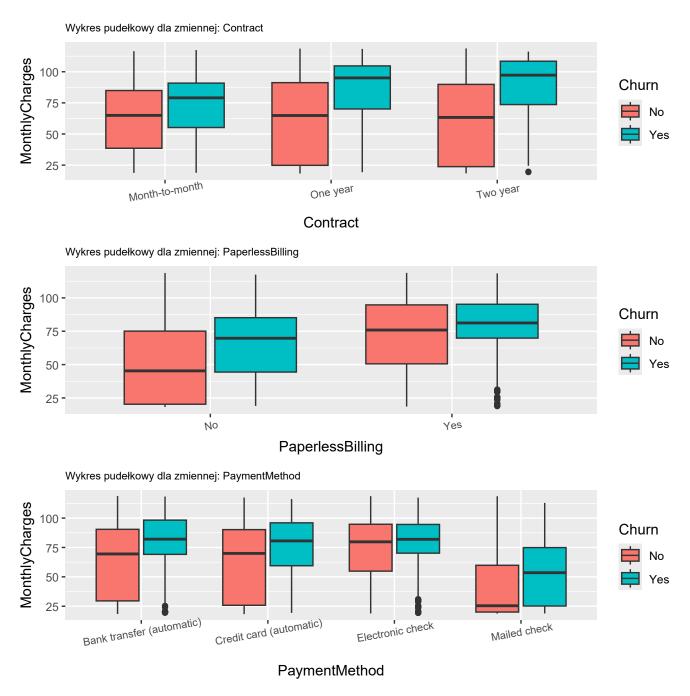
Rysunek 18: Wykresy pudełkowe wybranych zmiennych jakościowych w zależności od miesięcznej opłaty z uwzględnieniem zmiennej Churn

Z rysunku 18 widzimy, że w każdej zmiennej byli klienci mają większą medianę bez względu na wybraną opcję, poza InternetService. Warto jednak zwrócić uwagę na kilka wartości odstających wśród byłych klientów w zmiennej DSL, które mają większą wartość, niż 3. kwartyl wśród obecnych klientów.



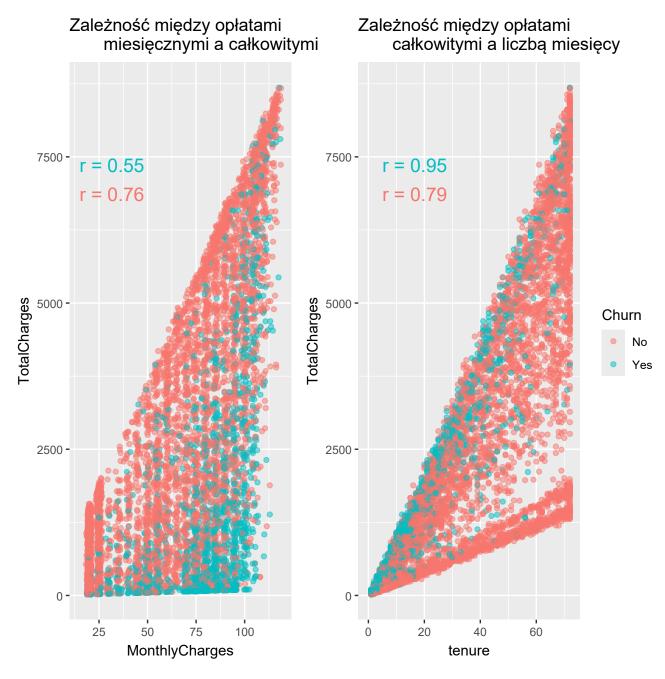
Rysunek 19: Wykresy pudełkowe wybranych zmiennych jakościowych w zależności od miesięcznej opłaty z uwzględnieniem zmiennej Churn

Wykresy 19 pokazują, że w każdej z dostępnych opcji dla klientów z wykupionym internetem, koszty dawnych konsumentów są większe niż obecnych.



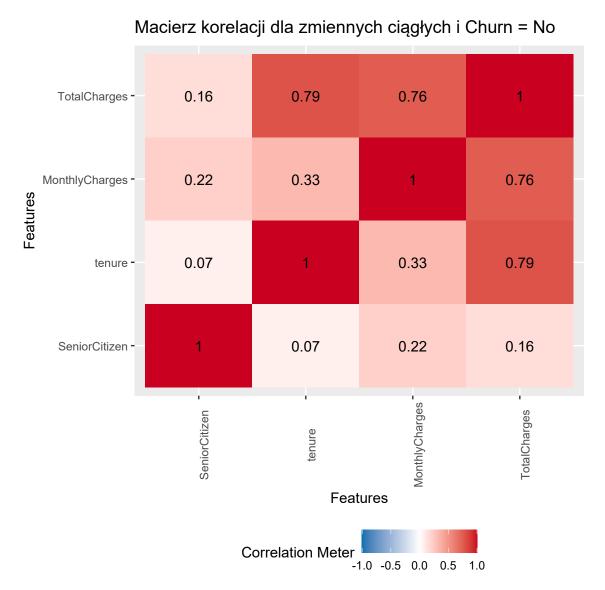
Rysunek 20: Wykresy pudełkowe wybranych zmiennych jakościowych w zależności od miesięcznej opłaty z uwzględnieniem zmiennej Churn

Na wykresach 20 również widać, że w każdej opcji byli klienci płacili więcej, a opłaty aktualnych konsumentów są bardziej zróżnicowane. Zbadajmy jeszcze wykres rozrzutu dla wybranych zmiennych ciągłych z uwzględnieniem cechy Churn.



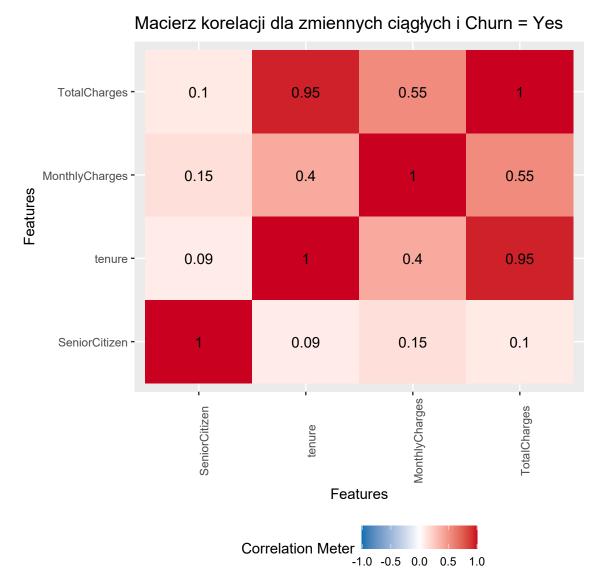
Rysunek 21: Wykres rozrzutu dla zmiennych Monthly
Charges i Total Charges oraz tenure i Total Charges w zależności od Churn

Z lewego wykresu rozrzutu na rysunku 21 jesteśmy w stanie odczytać, że klienci o wysokich miesięcznych opłatach i małych opłatach ogólnych to klienci, którzy odeszli. Wykres po prawej pokazuje silną korelację między cechą tenure a TotalCharges dla grupy nieaktywnych konsumentów. Widać, że punkty ich reprezentujące tworzą mniej więcej prostą linię, pod którą są klienci aktywni. Spójrzmy jeszcze raz na macierze korelacji, tym razem z uwzględnieniem zmiennej Churn.



Rysunek 22: Macierz korelacji dla zmiennych ciągłych z podziałem ze względu na zmienną Churn = No (bez brakujących wartości)

Z macierzy 22 widać, że klienci, którzy pozostali, mają podobną wartość korelacji między zmiennymi TotalCharges i tenure oraz TotalCharges i MonthlyCharges. Podobnie jak wcześniej, SeniorCitizen za bardzo nie wpływa na inne wartości. Natomiast u byłych klientów można zauważyć (z macierzy 23) bardzo silną korelację między TotalCharges a tenure oraz słabszą, niż w poprzednim przypadku, korelację między MonthlyCharges i TotalCharges.



Rysunek 23: Macierz korelacji dla zmiennych ciągłych z podziałem ze względu na zmienną Churn = Yes (bez brakujących wartości)

4 Podsumowanie

4.1 Ogólne wnioski o klientach

Większość klientów stanowią osoby związane z firmą przez okres krótszy niż 2.5 roku. Do grupy najliczniejszych miesięcznych kosztów należą opłaty o kwocie nieprzekraczającej 25 dolarów oraz te z przedziału 75-100 dolarów. Najpopularniejszą usługą wśród naszych klientów jest PhoneService oraz InternetService. Mniej są popularne dodatki do tych opcji (w większości $\leq 35\%$), jednak wyróżnia się zainteresowanie w dodatkach StreamingTV i StreamingMovies. Mimo, że światłowód wydaje się być najdroższą opcją internetu, to i tak jest najczęściej wybieranym rodzajem połączenia. Najczęściej wybierany jest kontrakt miesięczny, a opłaty osób, które go wybrały, są wyższe i mniej zróżnicowane niż klientów o rodzaju kontraktu przekraczającym jeden rok. Ogólne wydatki klientów i ich związek z firmą rośnie mniej więcej liniowo, co podkreśla silna korelacja z rysunku 11 między zmiennymi TotalCharges i tenure. Co do danych demograficznych, to można zauważyć podobną liczbę kobiet i mężczyzn, małą liczbę seniorów oraz osób, które mają kogoś na utrzymaniu.

4.2 Wnioski o klientach odchodzących

Podsumowując, aż 27% z klientów w tabeli odeszło w przeciągu ostatniego miesiąca. Większość z nich wyróżniały:

- Wysokie opłaty miesięczne, szczególnie przy opcji płatności zwykłym czekiem (rysunek 20, wykres zmiennej PaymentMethod, zmienna Mailed Check)
- Krótki okres współpracy z firmą
- Opcja światłowodu w cesze InternetService
- Zdecydowanie się na miesięczny kontrakt
- Brak osób do utrzymania (zmienna Dependetns)

Aby móc utrzymać klientów, można obniżyć cenę światłowodu, albo wprowadzić zniżki na inne powiązane usługi przy zakupie tej opcji. Firma mogłaby również wprowadzić lepszą ofertę kontraktów rocznych i dwurocznych. Na przykład, przy umowie rocznej, miesięczne opłaty byłyby mniejsze niż przy normalnym kontrakcie miesięcznym, ale byłaby gwarancja, że klient będzie związany przez co najmniej 12 miesięcy, co jest lepszym wynikiem niż mediana ze zmiennej tenure dla niekatywnych już konsumentów.